大數據分析

作業一

(Programming Assignment1)

410921202 資工四 林芷萱

- \ The problem description

此次作業的要求為使用 python 寫一個程式爬取 https://www.imdb.com/chart/top/?ref=nv_mv_250 的資料,分為兩個部分; Part A 為爬取前 250 個電影的 rank、name、year、duration、rating、rate 並存入 csv 檔,檔名為 films250.csv; Part B 為將前 250 個電影的 duration全部加起來。

— \ Highlight of the way you write the program

Part A:

這部分的重點在於怎麼處理 missing data, 我先爬取 year、duration、rating, 然後先將每一個都設為 None, 接著再判斷裡面的值。duration 的資料會出現 h 或 m ,所以如果有 h 或 m 的資料就是 duration;觀察 year 跟 rating 兩個資料的差異會發現 rating 的資料是英文、數字、符號混和,而 year 全部由數字組成,因此只要資料只有數字就是年份,否則則為 rating。

接著再將三個值依序放入對應的位置,如果沒有這個值,他就是 missing data。

```
# 處理year, duration, rating
metadata_element = movie.find(class_='sc-6fa21551-7 jLjTzn cli-title-metadata')
#print(metadata items)
metadata_items = metadata_element.find_all(class_='sc-6fa21551-8 bnyjtW cli-title-metadata-item')
year = None
duration = None
rating = None
for item in metadata items:
    text = item.text.strip()
    if 'h' in text or 'm' in text: # 如果有h或m就代表是duration
       duration = text
    elif text.isdigit(): # 如果只有數字就是年份
       year = text
       rating = text
# 處理missing data
movie year = year if year else "missing data"
movie_duration = duration if duration else "missing data"
movie rating = rating if rating else "missing data"
```

Part B:

這部分我的作法是分別把 h 跟 m 前面的數字加起來,如下:

```
for durations in all_durations:
    parts = durations.split()
    for part in parts:
        if part.endswith("h"):
            hours = int(part[:-1]) # 取得小時
            total_hours += hours
        elif part.endswith("m"):
            minutes = int(part[:-1]) # 取得分鐘
            total_minutes += minutes
```

接著再做進位:

```
# 把分鐘換成小時,有超過進位

if total_minutes >= 60:
    additional_hours = total_minutes // 60
    total_hours += additional_hours
    total_minutes %= 60
```

三、 The program listing

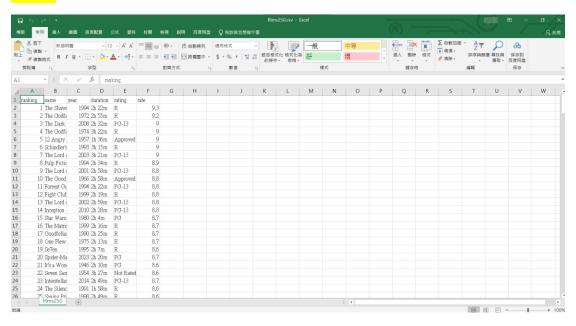
```
In [27]: import requests
    from bs4 import BeautifulSoup as BF
    import csv

In [28]: url = 'https://www.imdb.com/chart/top/?ref_=nv_mv_250'
    headers = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/100.0.0 Safari/537.3
        'Cookie': 'language=en_US',
        'Accept-Language': 'en-US,en;q=0.5'
    }
    html = requests.get(url, headers=headers)
    sp = BF(html.text, 'html.parser')
```

Part B

四、 Test run results

Part A:



Part B:

537 hours 59 minutes

五、 Discussion

在這次的作業當中我學習到了如何使用爬蟲爬取需要的資料以及要怎麼將檔案存進 csv 檔,在進行的過程中遇到比較大的問題是,我發現在爬取時資料會自動爬取成中文,這會導致 csv 檔打開來是亂碼,儘管我將 encoding 設為 utf-8 也一樣,最後我在 headers 加入了這兩行程式碼:

'Cookie': 'language=en_US',

'Accept-Language': 'en-US,en;q=0.5'

這使得爬蟲爬取該網頁時會強制使用英文,就沒有出現爬取到中文資料的問題了。